

機械学習 & 画像処理論文紹介セミナー

# A Collaborative Superpixelwise Autoencoder for Unsupervised Dimension Reduction in Hyperspectral Images

Yao+ (2023)

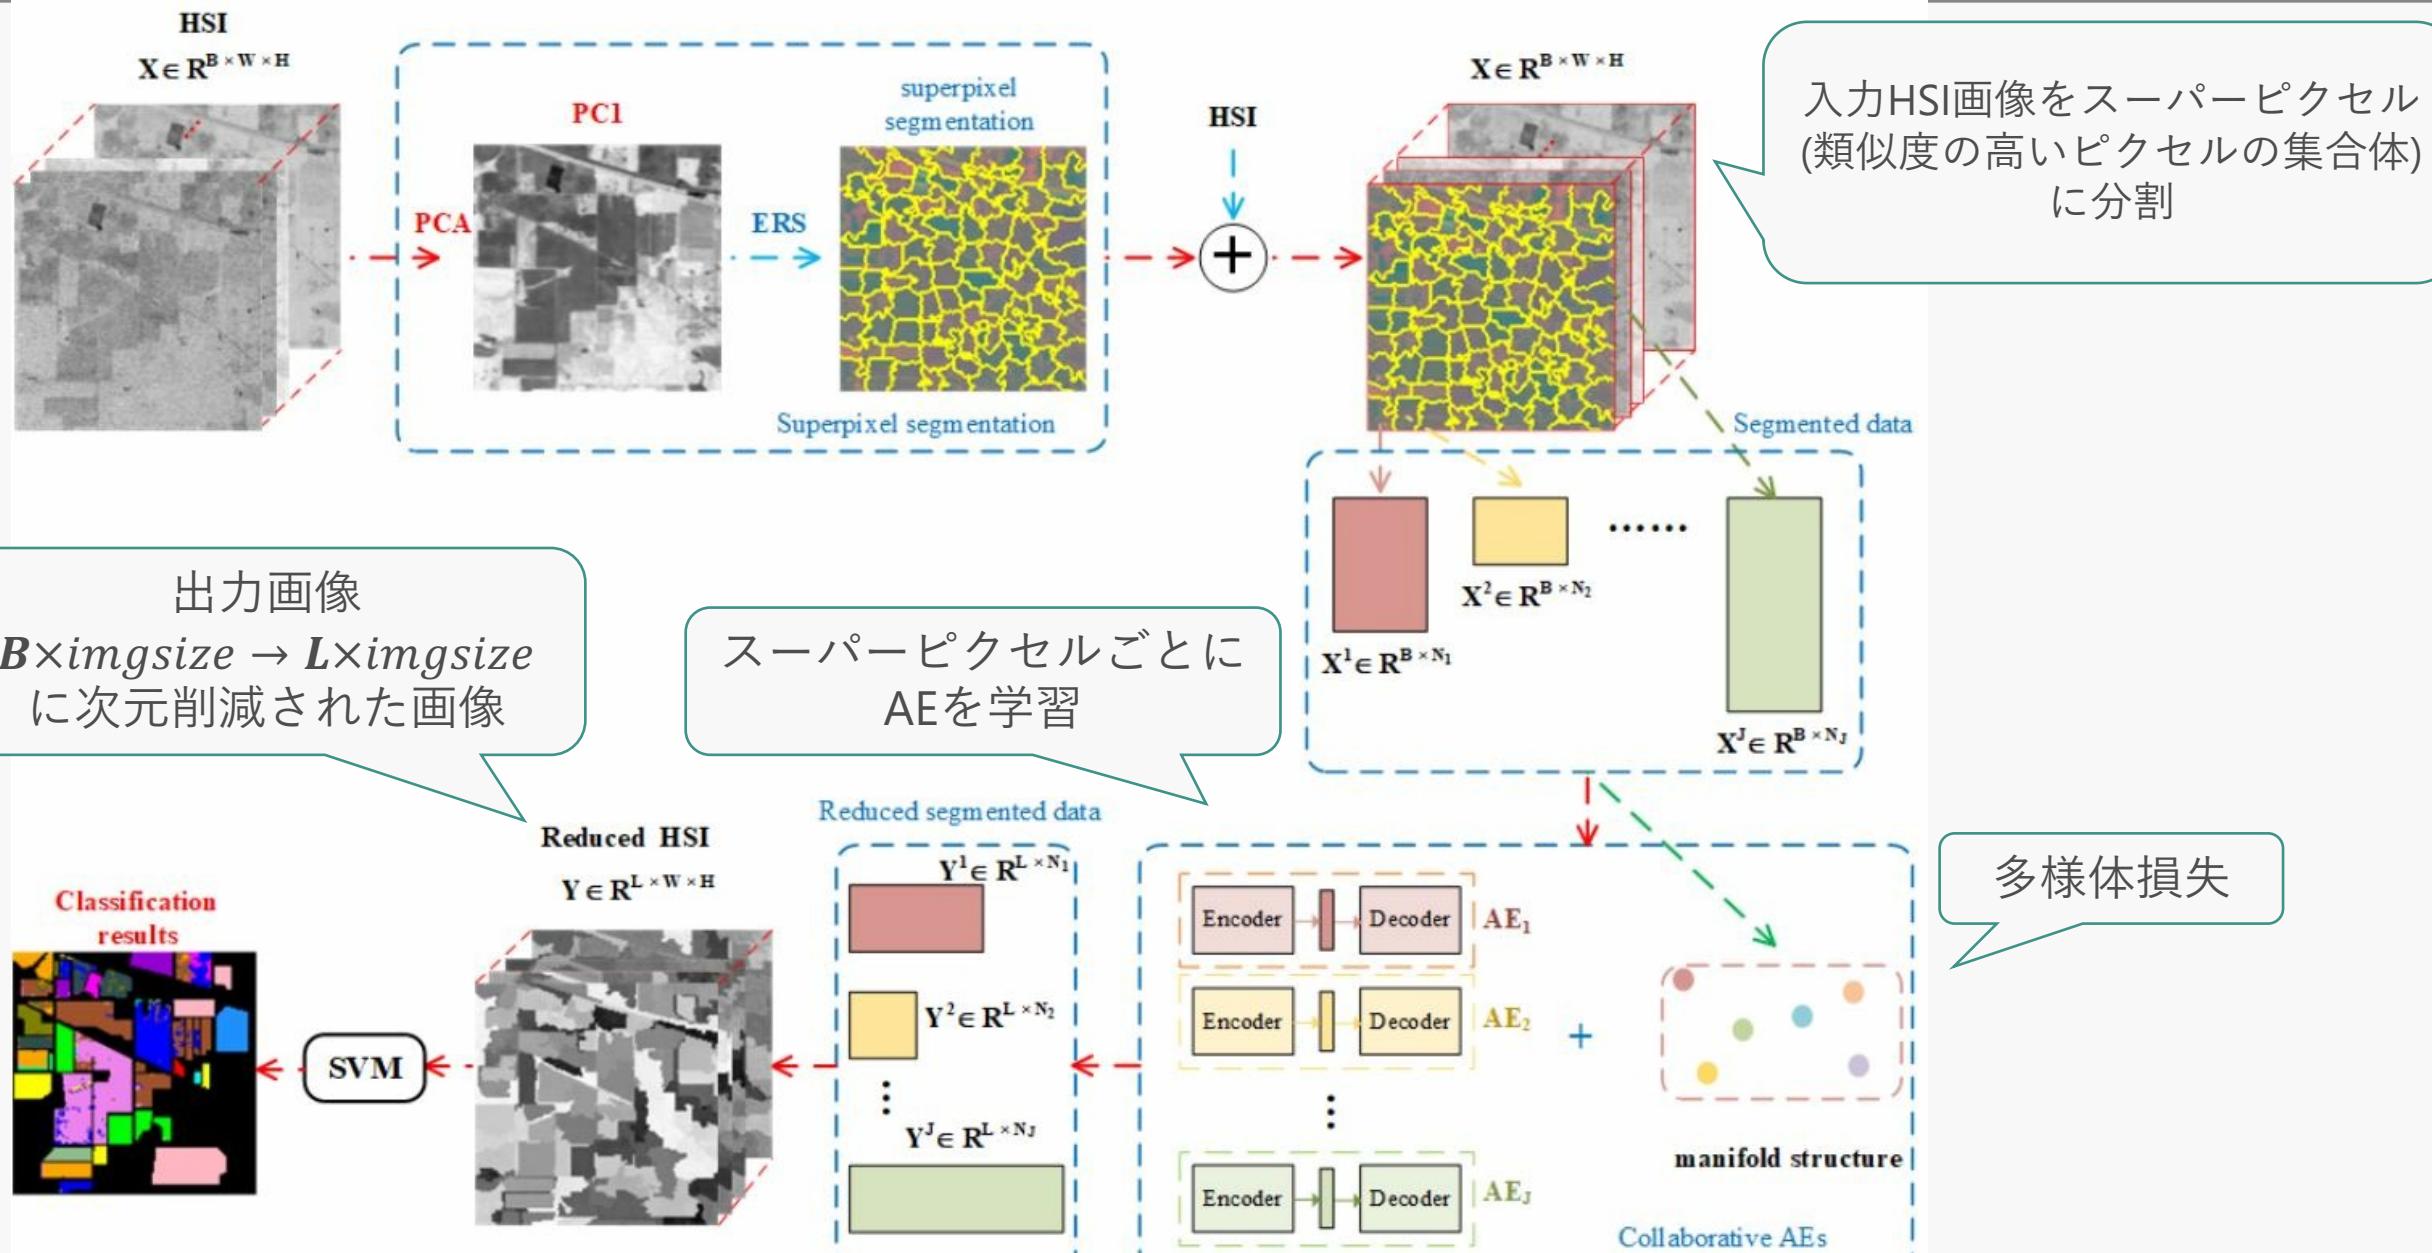
---

s1290162 Nakamura Zen

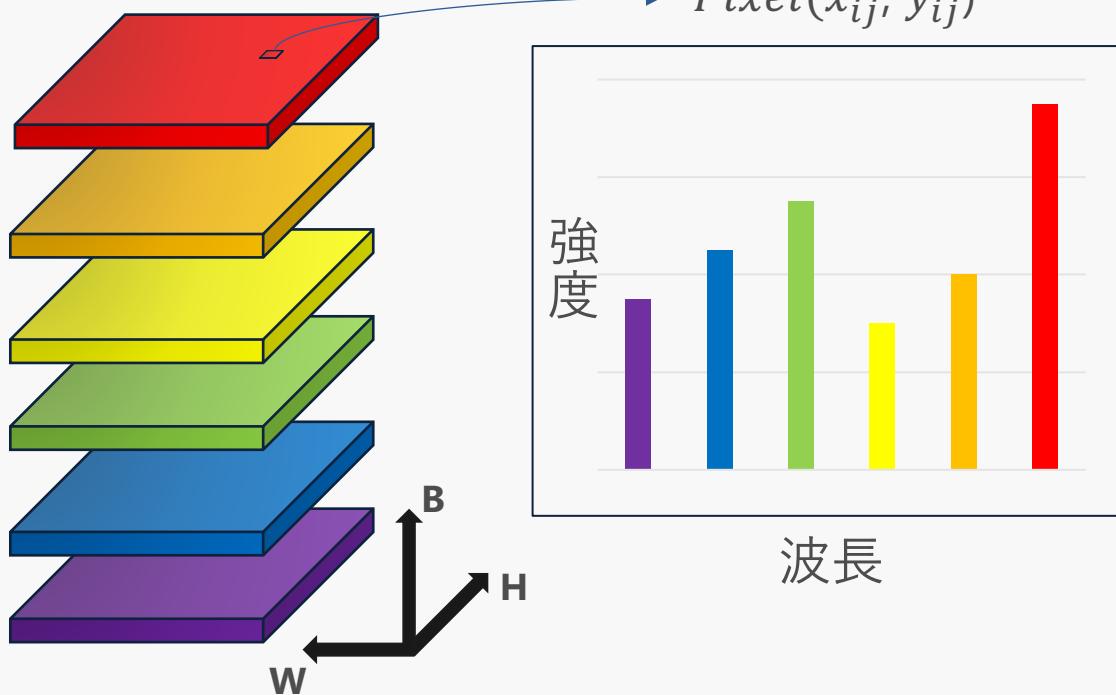
- タイトル
  - A Collaborative Superpixelwise Autoencoder for Unsupervised Dimension Reduction in Hyperspectral Images
- 著者
  - Chao Yao, Lingfeng Zheng, Longchao Feng, Fan Yang, Zehua Guo, Miao Ma
- 出版
  - Received: 21 July 2023 / Revised: 23 August 2023 / Accepted: 24 August 2023 / Published: 27 August 2023
- DOI: <https://www.mdpi.com/2072-4292/15/17/4211>

# 概要 : ColAE (Collaborative Superpixelwise Auto-Encoder)

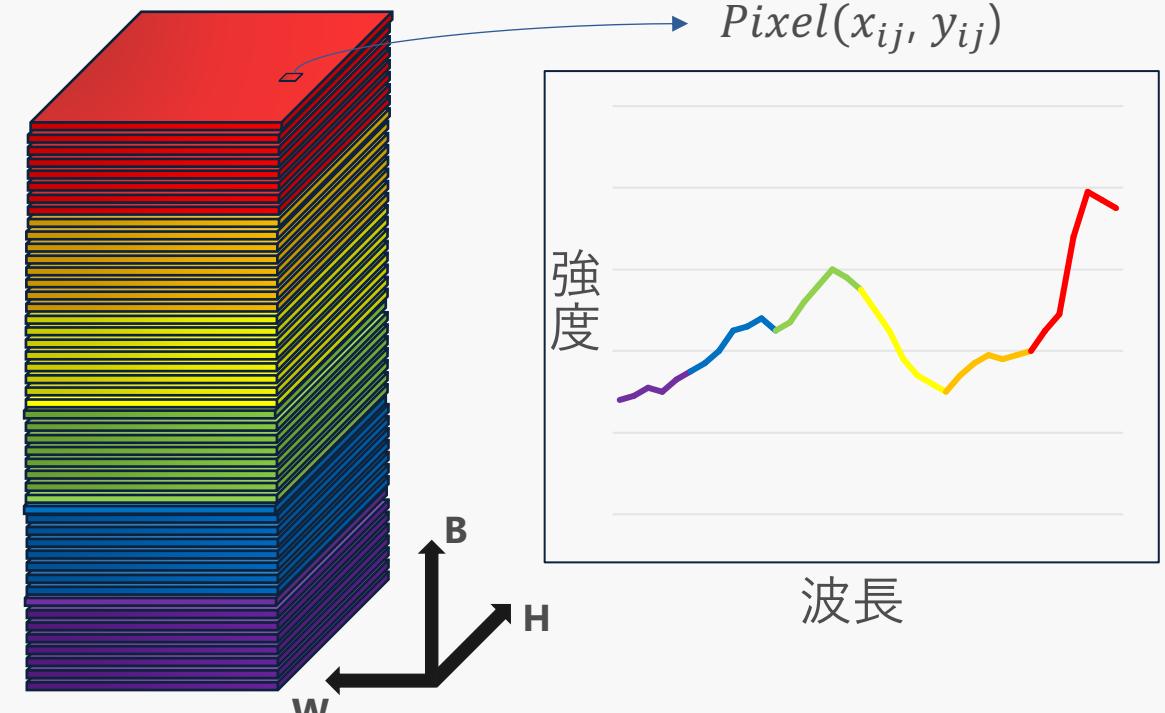
3



## マルチスペクトル画像 (MSI)



## ハイパースペクトル画像 (HSI)



## ● HSIの課題

- 冗長でノイズの多い情報が含まれる
- 特徴量が増えるにつれて機械学習における「次元の呪い」問題が生じる
- 高い計算量とストレージ容量を必要とする



## 解決策

## ● HSI分類のための一般的な次元削減手法 (DR)

### ● バンド選択

- バンドサブセットを選択することで次元を削減する
- 課題
  - 最適なバンドサブセットを見つけるのに苦労することが多い

### ● 特徴抽出 (提案手法)

- 変換された特徴空間におけるデータのコンパクト表現を見つける

### 機械学習のタイプ

#### 教師あり

- 線形判別分析 (LDA)
- LDAにおける非線形分離問題
- LDAとスパース学習の組み合わせ

#### 教師なし (提案手法)

- 主成分分析 (PCA) ← 線形手法
- 局所多様体モデル ← 非線形手法

#### 半教師あり

- 局所判別分析
- 局所フィッシャー判別分析

#### 深層学習

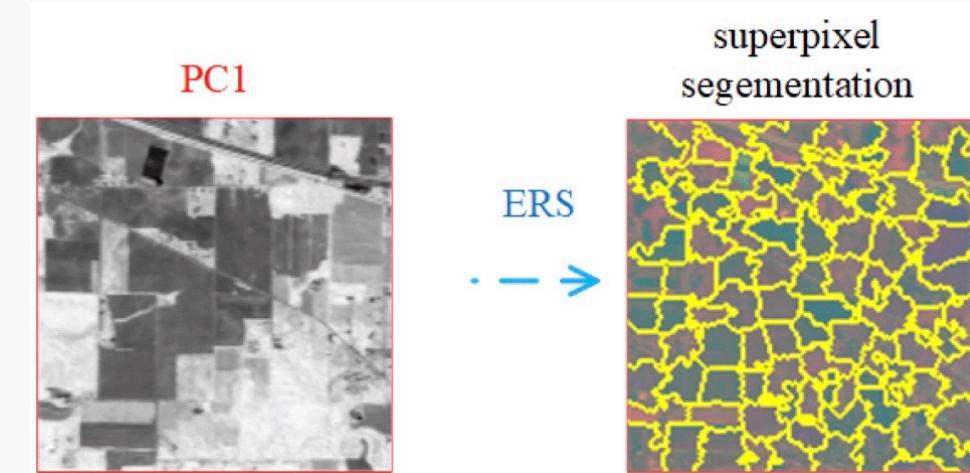
- Autoencoder

## ● スーパーピクセルベース手法 (提案手法)

- HSIを均一な領域（スーパーピクセル）に分割し、各領域それぞれにDR手法を適用
- 先行研究
  - 各スーパーピクセルから特徴を抽出するためにPCAを使用
  - 同スーパーピクセルのピクセルを重み付し、分類のためのスパース表現を評価
  - スーパーピクセル内のサンプルにkernel PCAを採用

## ● ピクセル近傍ベース手法

- 空間情報を取り組むために局所的なピクセルパッチを考慮
- 先行研究
  - LPNPE
  - 局所共分散行列
  - 空間窓による距離尺度の定義
  - Stack Auto-Encoder



### Superpixel Segmentation

画像を類似度に基づく pixel の集合体で分割

## ● スーパーピクセルベース手法の課題

- 既存の手法 (SuperPCA, S3 PCA, S-RAE) は、各スーパーピクセル領域から個別に特徴を抽出  
→ 異なるスーパーピクセル領域からのサンプル間の関係を無視

||

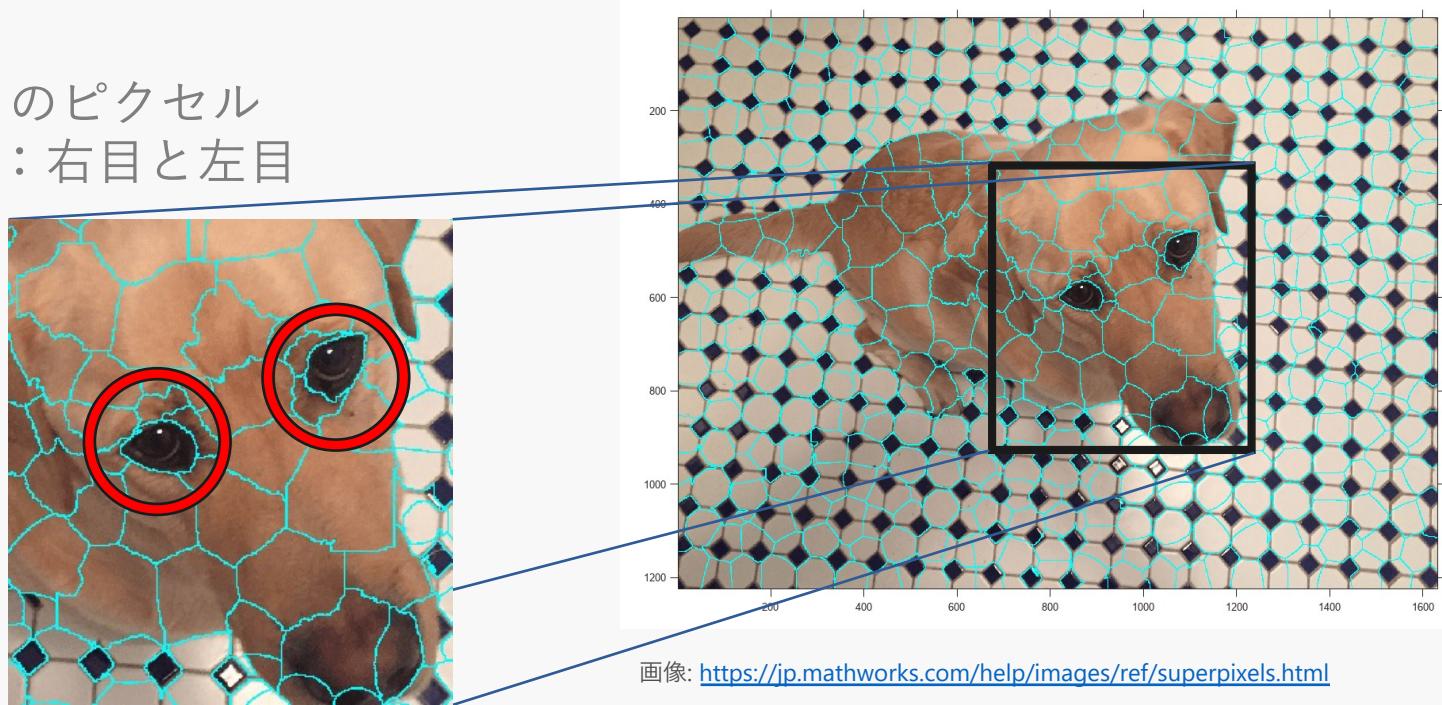
- 同じカテゴリのサンプルが異なる領域に位置する可能性があり、データ内のクラス内格差の増加

例)

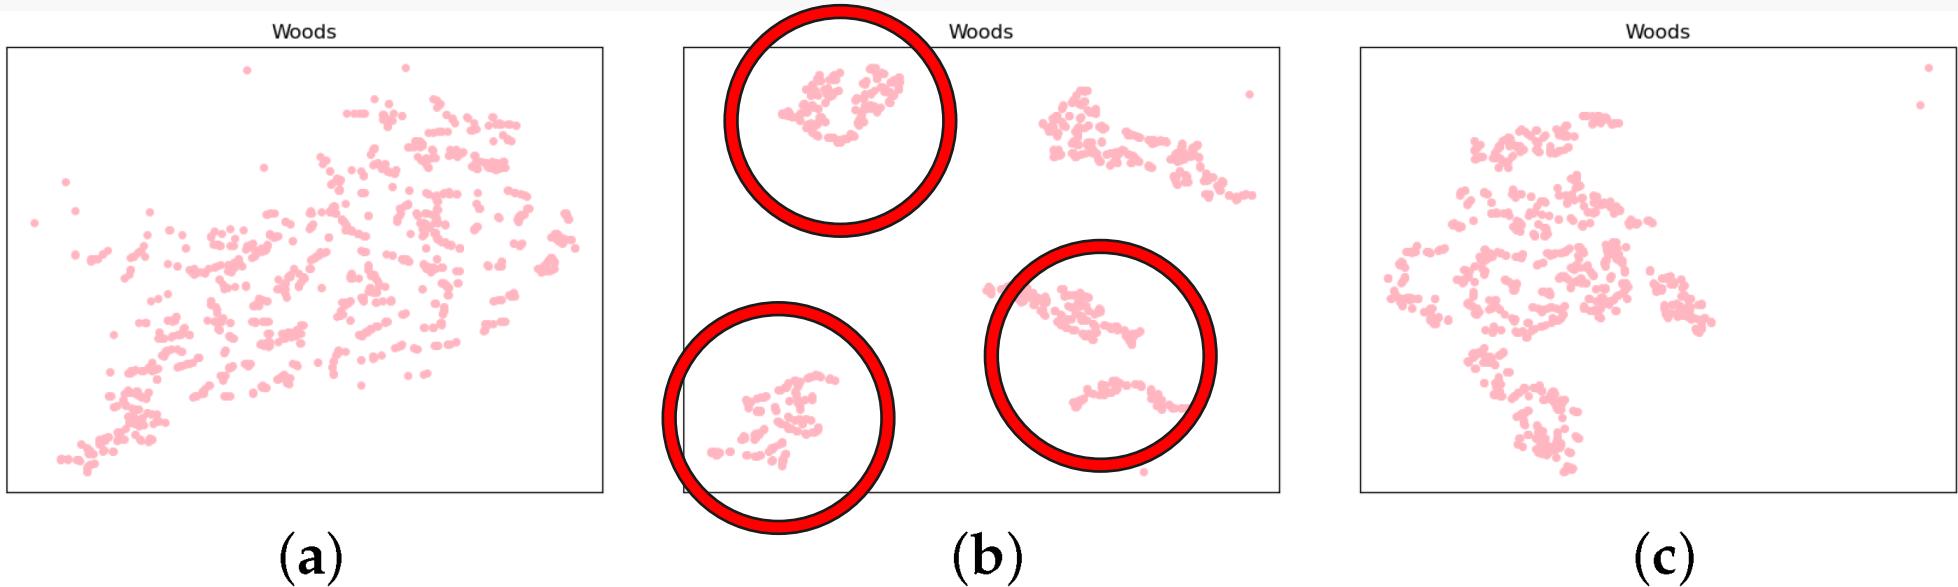
- 同じカテゴリのサンプル：目のピクセル
- 異なるスーパーピクセル領域：右目と左目



- パフォーマンスの低下を招く



## ● Indian Pinesデータセットのwoodsカテゴリの例



(a) オリジナル空間

クラス内の一貫性が高い

(b) SuperPCAを適用

クラス内の一貫性が崩壊

(c) ColAE (提案手法)

※ T-SNEを使用して可視化



クラス内構造の喪失が、HSIのタスク（分類, セグメンテーションなど）に悪影響を及ぼす可能性がある

## ● CoIAE

- 教師なしの非線形な次元削減手法
- Entropy Rate Segmentation (ERS)
  - 2Dスーパーピクセルマップを生成するために使用
- Locally Linear Embedding (LLE)
  - 各スーパーピクセル内の平均ベクトルの多様体構造を保つするために使用
- Auto-Encoder (AE)
  - AEの再構成誤差とLLEの多様体損失を損失関数として各スーパーピクセルごとにAEを学習し、符号空間（コンパクト表現）を使用

## ● 検証

- 学習したコンパクト表現をサポートベクターマシン (SVM) に入力し、カテゴリを決定して評価する
- 3つのハイパースペクトルデータセットを用いて実験を行った

## ● ERSの採用理由

- HSI分類タスクにおいて有望な性能が示されている

1. Jiang+ (2018): A superpixelwise PCA approach for unsupervised feature extraction of hyperspectral imagery  
→ 理由: 前処理プロセスで用いるため計算量を少なくする必要があるため

2. Zhang+ (2022): Spectral-spatial and superpixelwise PCA for unsupervised feature extraction of hyperspectral imagery

- 適用的領域生成とテクスチャ保存における固有の能力がある？

## ● ERSの概要

- $G = (V, E)$  ( $V$ : ピクセルの集合,  $E$ : 2つのピクセル対の類似性を表す)
- 連結部分グラフ  $G^* = (V, A)$  ( $A \subseteq E$ ) が  $K$  個になるように辺の部分集合  $A$  を選択する

- ERSの目的関数

$$\mathbf{A}^* = \arg \max_{\mathbf{A}} \text{Tr}(H(\mathbf{A}) + \alpha B(\mathbf{A}), s.t. \mathbf{A} \subseteq \mathbf{E},$$

- $H(A)$ : エントロピー率 (均一でコンパクトなクラスタを見つける)
- $B(A)$ : バランス項 (同程度のサイズのクラスタを作る)
- $\alpha$ :  $H(A)$  と  $B(A)$  をバランスを取るための重み

## ● LLEの概要

1. 局所近傍内のサンプルは線形に位置すると仮定し（多様体）、あるベクトル  $x_i$  とその  $x_i$  の  $k$ -最近傍ベクトルの線型結合の二乗誤差を最小にしていき、線型結合の係数（重み行列  $W$ ）を見つける
2. その重みを使い、 $x_i$  から低次元表現  $y_i$  を見つける

## ● LLEの損失関数

1. 重み行列  $W$  を見つける

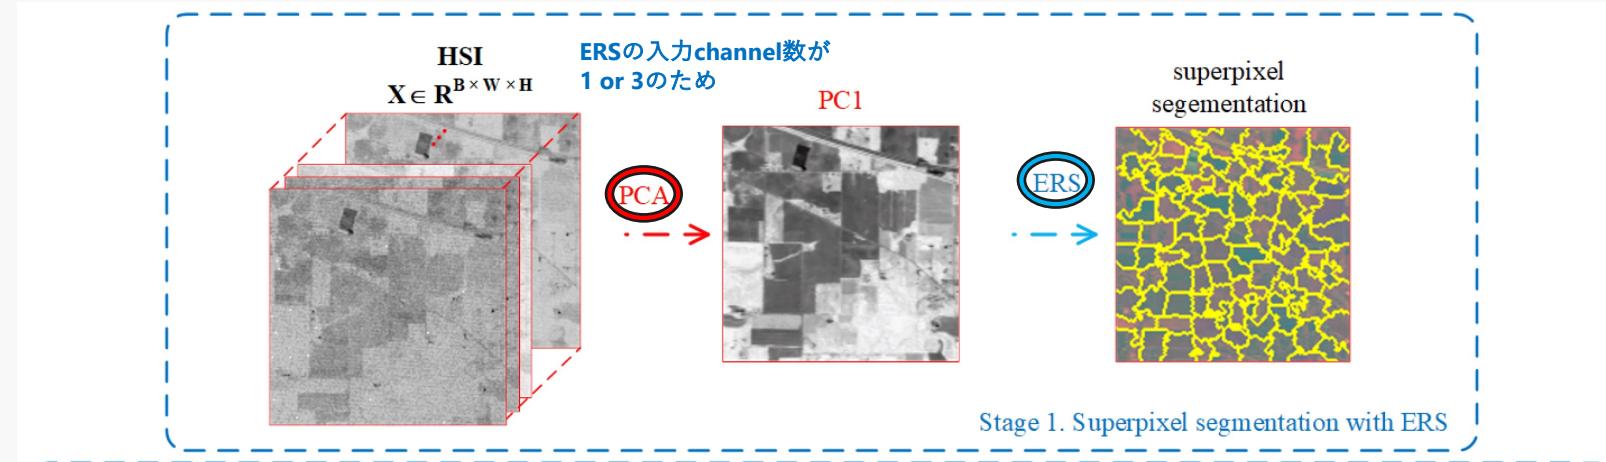
$$\varepsilon(\mathbf{W}) = \sum_i \|\mathbf{x}_i - \sum_{\mathbf{x}_j \in \mathcal{N}_i} w_{ij} \mathbf{x}_j\|^2, \text{ s.t. } \sum_j w_{ij} = 1,$$

2. 低次元表現を見つける

$$\Phi(\mathbf{Y}) = \sum_i \|\mathbf{y}_i - \sum_j w_{ij} \mathbf{y}_j\|^2.$$

## ● Stage 1. 前処理

- ERSにより均一な領域  
(スーパーピクセル) に分割する

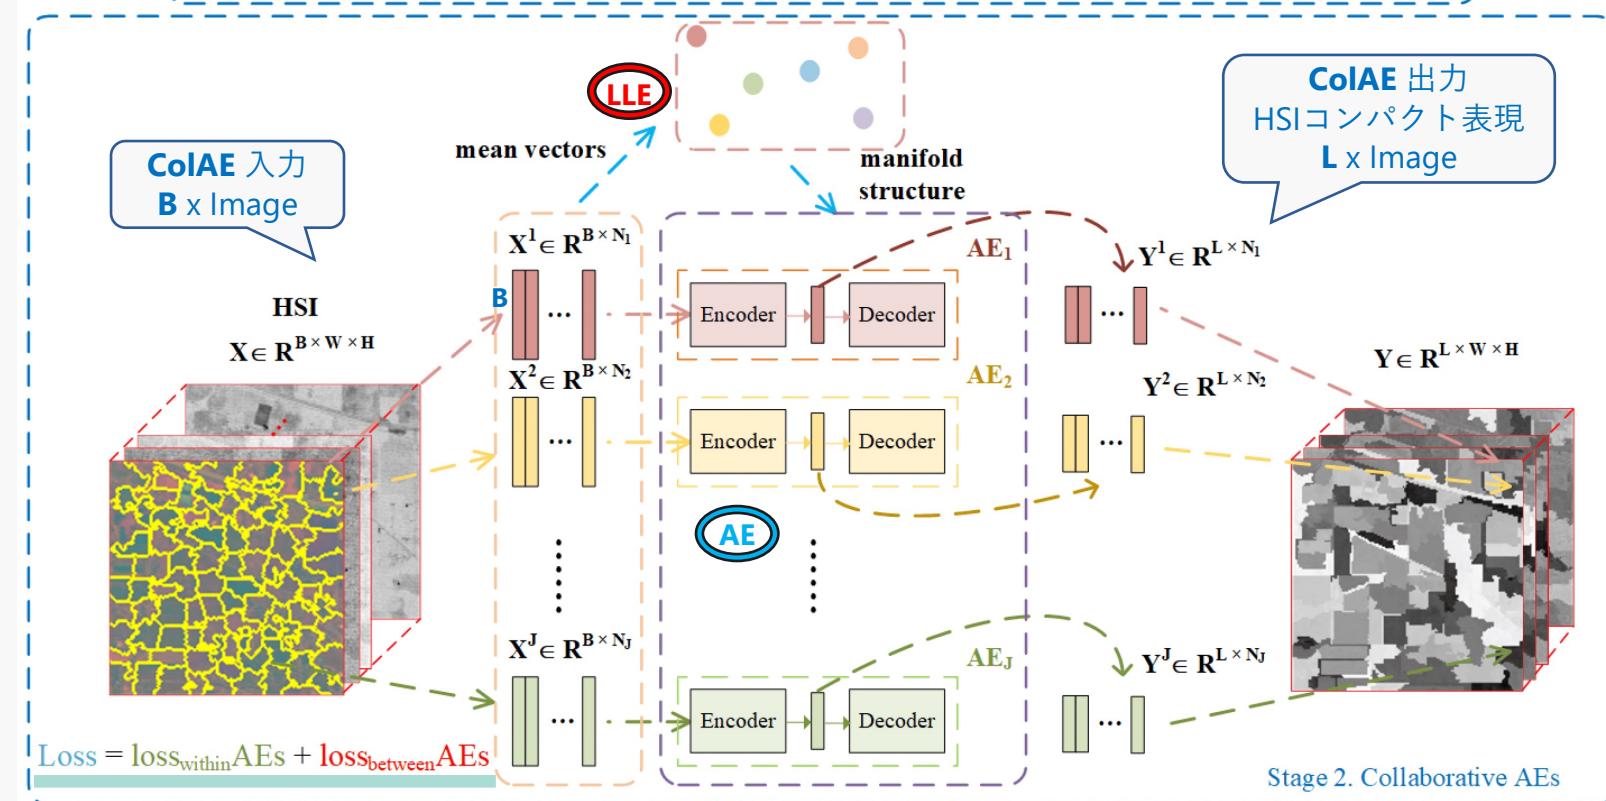


## ● Stage 2. CoIAEの学習

- $J$ 個 (スーパーピクセルの数) のAEを学習

### (2つの損失関数)

1. Auto-Encoderの再構成誤差
2. LLEの再構成誤差
  - 各Superpixel内の平均ベクトルの多様体構造を保つ



$$R(\Theta) = \sum_i \sum_j \|x_j^i - \hat{x}_j^i\|^2 + \eta \sum_i \left\| \sum_j \frac{1}{N_j} y_j^i - \sum_k w_{ik} \sum_j \frac{1}{N_k} y_j^k \right\|^2$$

iじゃない?

- 1項: AEの再構成誤差

- $x_j^i$ :  $i$ 番目のスーパーピクセルの  $j$  番目のサンプル
- $\hat{x}_j^i$ :  $x_j^i$  を入力とした  $i$  番目のAEの出力

- 2項: 多様体損失

- $y_j^i$ :  $i$  番目のAEの符号空間  
( $i$  番目のスーパーピクセルの  $j$  番目のサンプルのコンパクト表現)
- $N_i$ :  $i$  番目のスーパーピクセルのサンプル数
- $w_{ik}$ :  $i$  番目のベクトルの  $k$  番目の近傍の重み

LLEの式

$$\sum_i \left\| \mathbf{y}_i - \sum_j w_{ij} \mathbf{y}_j \right\|^2$$

$i$  番目のスーパーピクセルの  
符号空間の平均ベクトル  $\mu'^i$

$$\sum_i \left\| \sum_j \frac{1}{N_i} \mathbf{y}_j^i - \sum_k w_{ik} \sum_j \frac{1}{N_k} \mathbf{y}_j^k \right\|^2$$

$k$  番目のスーパーピクセルの  
符号空間の平均ベクトル  $\mu'^k$

# 実験結果 (1/) : 3つのHSIデータセット

[https://www.ehu.eus/ccwintco/index.php?title=Hyperspectral\\_Remote\\_Sensing\\_Scenes](https://www.ehu.eus/ccwintco/index.php?title=Hyperspectral_Remote_Sensing_Scenes)

これらすべてのデータセットは上記から入手可能

15

Table 1. Number of samples in the Indian Pines, University of Pavia, and Salinas images.

## ● Indian Pines

- 400-2500 nm, 224バンド, 145x145 pixels

- 水の吸収領域をカバーする24バンドを除去し、合計200バンドを使用
- 約10,249のラベル付きサンプルはground-truth mapからのものである

## ● University of Pavia

- 430-860 nm, 115バンド, 610x340 pixels

- ノイズと水バンドを合計12除去し、合計103バンドを使用
- 約42,776のラベル付きサンプルはground-truth mapからのものである

## ● Salinas

- 400-2500 nm, 224バンド, 512x217 pixels

- ノイズと水バンドを合計20除去し、合計204バンドを使用
- 約53,129のラベル付きサンプルはground-truth mapからのものである

Indian Pines		University of Pavia		Salinas	
Class Name	Numbers	Class Name	Numbers	Class Name	Numbers
c1 Alfalfa	46	Asphalt	6631	Broccoli green weeds 1	2009
c2 Corn-notill	1428	Meadows	18,649	Broccoli green weeds 2	3726
c3 Corn-mintill	830	Gravel	2099	Fallow	1976
c4 Corn	237	Tress	3064	Fallow rough plow	1394
c5 Grass-pasture	483	Mental sheets	1345	Fallow smooth	2678
c6 Grass-tress	730	Bare soil	5029	Stubble	3959
c7 Grass-pasture-mowed	28	Bitumen	1330	Celery	2579
c8 Hay-windrowed	478	Bricks	3682	Grapes untrained	11271
c9 Oats	20	shadow	947	Soil vineyard develop	6203
c10 Soybean-notill	972			Corn senesced green seed	3278
c11 Soybean-mintill	2455			Lettuce romaine 4wk	1068
c12 Soybean-clean	593			Lettuce romaine 5wk	1927
c13 Wheat	205			Lettuce romaine 6wk	916
c14 Woods	1265			Lettuce romaine 7wk	1070
c15 Buildings-grass-trees-dirves	386			Vineyard untrained	7268
c16 Stone-steel-towers	93			Vineyard vertical trellis	1807
Total number		10,249	Total number	42,776	Total number
					54,129

クラス数が比較的少ない

## ● ColAEと比較する10個の次元削減手法

### ● 一般的な次元削減手法

- PCA, LPP (線形モデル)
- KPCA (非線形モデル)

〔● AE (非線形モデル) ← Encoder, Decoderそれぞれ2層 (活性化関数1つ)

### ● スーパーピクセルベース手法

- SuperPCA, SuperLPP, SuperKPCA

〔● SuperAE

### ● スペクトルのみ

〔● CAE (3D-Convolutional Auto-Encoder)

〔● ContrastNet (対照学習とAuto-Encoderの組み合わせ)

深層学習ベースの手法

## ● 評価指標

- Overall Accuracy
- Average Accuracy
- Kappa

- 提案手法をテストするために、<https://github.com/junjunjiang/SuperPCA/tree/master/datasets>の10個のランダム分割セットを訓練とテストに用いる
- 3つのデータセットの各クラスについて、SVMの訓練データセットとテストデータセット
  - 訓練データ:  $T=3, 5, 7, 10, 15, 20$ のサンプル
  - テストデータ: 残りのサンプル
- 次元削減した時の次元数は  $L = 30$

# 実験結果 (4/) : 訓練結果

- ほぼ全ての結果において、CoIAEは他の手法を上回り、その優れた性能を示す
- Indian Pinesデータセットでは、SuperPCAがCoIAEよりも優れたAverage Accuracy (AA) を示したが、Overall Accuracy (OA) とkappaに基づいて評価すると、CoIAEはSuperPCAを上回る

Data Set	T.N.s/C	Metric	Raw	PCA	LPP	KPCA	AE	Super PCA	Super LPP	Super KPCA	Contrast Net	CAE	SuperAE	CoIAE
Indian Pines	3	OA(%)	40.89	40.89	45.01	40.81	40.37	54.55	58.28	48.28	55.20	54.50	67.78	<b>68.81</b>
		AA(%)	44.30	44.21	45.60	43.97	44.00	<b>74.69</b>	71.32	53.78	55.31	54.06	70.15	66.41
		kappa	0.3455	0.3455	0.3870	0.3451	0.3404	0.4837	0.5276	0.4415	0.4977	0.4942	0.6397	<b>0.6518</b>
	5	OA(%)	47.41	46.98	53.56	47.52	47.72	69.84	65.86	64.30	67.88	64.28	77.20	<b>77.72</b>
		AA(%)	48.60	48.38	52.23	48.43	48.65	80.91	76.43	61.22	60.73	60.81	<b>77.49</b>	74.79
		kappa	0.4156	0.4115	0.4818	0.4158	0.4190	0.6560	0.6149	0.6061	0.6364	0.5992	0.7429	<b>0.7493</b>
	7	OA(%)	51.38	50.84	58.47	51.46	50.65	77.01	75.00	77.62	73.36	70.20	81.34	<b>82.03</b>
		AA(%)	51.53	50.77	55.71	50.92	50.54	86.13	81.14	<b>90.35</b>	66.80	65.16	80.78	80.18
		kappa	0.4578	0.4516	0.5351	0.4566	0.4509	0.7378	0.7178	0.7364	0.6995	0.6651	0.7892	<b>0.7969</b>
	10	OA(%)	54.68	53.98	61.31	54.44	53.71	83.19	83.80	73.91	76.60	75.83	85.09	<b>85.10</b>
		AA(%)	54.00	53.46	58.90	53.66	52.98	<b>85.31</b>	80.25	87.48	70.11	69.57	82.84	81.96
		kappa	0.4943	0.4867	0.5669	0.4908	0.4840	0.8084	0.8092	0.7055	0.7369	0.7278	0.8311	<b>0.8312</b>
	15	OA(%)	58.83	57.60	64.56	58.29	56.86	87.81	86.23	87.82	80.02	80.96	87.69	<b>88.02</b>
		AA(%)	56.67	55.70	60.88	55.80	54.66	<b>86.81</b>	80.64	89.99	70.17	73.07	83.38	82.04
		kappa	0.5401	0.5267	0.6034	0.5328	0.5190	0.8611	0.8442	0.8620	0.7803	0.7852	0.8603	<b>0.8640</b>
	20	OA(%)	61.57	60.53	67.26	61.26	59.83	89.13	88.24	87.93	84.44	84.46	89.18	<b>89.20</b>
		AA(%)	57.39	56.48	60.89	56.98	56.35	85.17	83.61	<b>89.66</b>	75.13	74.89	81.28	80.98
		kappa	0.5694	0.5578	0.6326	0.5654	0.5503	0.8765	0.8726	0.8631	0.8237	0.8241	0.8771	<b>0.8773</b>
University of Pavia	3	OA(%)	60.50	60.55	54.40	-	61.03	78.48	67.41	81.83	79.71	70.52	83.66	<b>84.04</b>
		AA(%)	64.73	64.62	56.80	-	65.25	73.94	72.72	73.99	81.67	74.61	83.54	<b>84.01</b>
		kappa	0.5154	0.5157	0.4341	-	0.5203	0.7222	0.5736	0.7615	0.7333	0.6239	0.7911	<b>0.7957</b>
	5	OA(%)	65.77	65.73	58.22	-	65.03	82.02	71.49	85.06	83.49	78.89	87.21	<b>87.40</b>
		AA(%)	68.53	68.49	59.97	-	68.56	78.94	75.25	80.49	85.11	81.10	86.40	<b>86.70</b>
		kappa	0.5731	0.5727	0.4788	-	0.5671	0.7675	0.6297	0.8061	0.7813	0.7300	0.8366	<b>0.8390</b>
	7	OA(%)	70.36	70.34	60.02	-	69.01	84.40	74.98	86.92	87.81	84.75	88.83	<b>89.43</b>
		AA(%)	72.03	71.92	61.92	-	70.70	82.89	79.18	83.32	86.66	84.79	87.24	<b>87.65</b>
		kappa	0.6253	0.6247	0.5016	-	0.6107	0.7988	0.6714	0.8305	0.8393	0.8033	0.8564	<b>0.8638</b>
	10	OA(%)	72.66	72.48	63.43	-	71.46	89.01	80.24	91.09	91.95	88.83	92.53	<b>92.74</b>
		AA(%)	74.12	73.95	64.54	-	72.85	87.22	83.33	89.87	90.37	87.97	90.94	<b>91.10</b>
		kappa	0.6553	0.6532	0.5450	-	0.6414	0.8577	0.7387	0.8836	0.8939	0.8545	0.9031	<b>0.9057</b>
	15	OA(%)	77.90	78.26	65.48	-	76.26	91.86	81.26	92.30	94.38	92.03	94.76	<b>94.93</b>
		AA(%)	77.03	77.13	66.57	-	75.32	89.56	83.74	91.29	92.70	90.55	93.10	<b>93.29</b>
		kappa	0.7169	0.7210	0.5734	-	0.6975	0.8938	0.7549	0.8982	0.9257	0.8957	0.9314	<b>0.9337</b>
	20	OA(%)	80.57	80.66	70.13	-	79.35	92.60	82.48	91.37	95.01	94.08	95.16	<b>95.39</b>
		AA(%)	78.84	78.84	69.32	-	77.40	90.79	85.38	89.52	93.34	92.49	93.29	<b>93.61</b>
		kappa	0.7497	0.7512	0.6254	-	0.7346	0.9034	0.7714	0.8865	0.9343	0.9222	0.9365	<b>0.9396</b>

※太字: 最良の結果

- ほぼ全ての結果において、CoIAEは他の手法を上回り、その優れた性能を示す

Data Set	T.N.s/C	Metric	Raw	PCA	LPP	KPCA	AE	Super PCA	Super LPP	Super KPCA	Contrast Net	CAE	SuperAE	CoIAE
Salinas	3	OA(%)	79.13	79.15	78.22	-	80.86	70.21	75.30	76.84	80.21	80.84	88.14	<b>89.46</b>
		AA(%)	83.48	83.48	83.38	-	86.34	73.75	79.16	89.20	81.93	84.38	90.91	<b>92.43</b>
		kappa	0.7687	0.7688	0.7598	-	0.7877	0.6729	0.7217	0.7435	0.7808	0.7874	0.8681	<b>0.8828</b>
	5	OA(%)	81.13	81.09	82.21	-	82.48	80.67	80.97	80.46	84.98	87.12	90.97	<b>91.97</b>
		AA(%)	85.86	85.88	87.55	-	87.96	84.59	87.58	78.96	86.78	89.04	94.29	<b>94.77</b>
		kappa	0.7906	0.7901	0.8035	-	0.8056	0.7859	0.7871	0.7835	0.8330	0.8570	0.8997	<b>0.9108</b>
	7	OA(%)	83.68	83.66	83.58	-	84.63	88.20	90.21	87.46	87.18	89.92	93.25	<b>94.01</b>
		AA(%)	87.79	87.74	88.09	-	89.47	90.75	93.69	90.28	88.62	91.18	95.94	<b>96.21</b>
		kappa	0.8188	0.8186	0.8176	-	0.8293	0.8692	0.8906	0.8602	0.8576	0.8883	0.9251	<b>0.9334</b>
	10	OA(%)	85.45	85.27	84.71	-	85.94	91.38	90.59	89.58	88.71	91.98	94.53	<b>94.83</b>
		AA(%)	89.15	89.09	89.30	-	90.34	94.45	93.99	93.03	90.26	92.91	96.51	<b>96.61</b>
		kappa	0.8382	0.8362	0.8305	-	0.8437	0.9036	0.8948	0.8892	0.8747	0.9109	0.9392	<b>0.9426</b>
	15	OA(%)	86.89	86.77	86.04	-	87.28	95.26	92.69	92.36	91.59	94.10	96.06	<b>96.14</b>
		AA(%)	90.63	90.55	90.68	-	91.45	96.10	94.32	94.66	92.48	94.69	97.18	<b>97.27</b>
		kappa	0.8543	0.8530	0.8450	-	0.8587	0.9471	0.9174	0.9146	0.9066	0.9345	0.9562	<b>0.9571</b>
	20	OA(%)	88.14	88.16	88.39	-	88.16	97.06	94.62	94.25	92.84	95.52	97.06	<b>97.20</b>
		AA(%)	91.44	91.48	91.80	-	92.09	96.89	93.43	94.38	93.70	95.91	97.55	<b>97.63</b>
		kappa	0.8680	0.8682	0.8809	-	0.8666	0.9633	0.9403	0.9359	0.9204	0.9503	0.9673	<b>0.9687</b>

※太字:  
最良の結果

# 実験結果 (6/) : 訓練結果 (クラス別)

20

Indian Pines データセット

	Raw	PCA	LPP	KPCA	AE	Super PCA	Super LPP	Super KPCA	Contrast Net	CAE	SuperAE	ColAE
c1	34.70	35.91	40.57	31.72	31.17	100.00	100.00	100.00	53.45	64.65	100.00	98.81
c2	47.50	45.38	54.40	46.80	44.93	78.82	75.48	58.02	78.22	72.38	78.10	78.89
c3	36.87	34.91	42.88	36.10	38.18	91.56	99.53	96.23	68.63	75.18	87.41	83.61
c4	32.52	30.66	40.47	31.64	28.79	82.44	69.10	86.56	48.66	58.29	69.31	65.46
c5	66.76	65.47	67.28	66.76	63.60	98.55	97.01	99.76	91.74	85.49	97.31	96.12
c6	89.97	89.40	88.21	89.38	88.07	99.80	99.43	100.00	93.11	90.27	99.76	99.89
c7	22.17	20.98	23.44	21.52	20.77	50.80	39.39	34.21	26.00	45.89	59.74	51.95
c8	98.39	98.32	96.91	98.33	98.41	98.57	98.72	100.00	97.68	94.95	99.98	100.00
c9	8.25	7.54	14.74	7.51	5.97	45.59	10.20	100.00	22.73	16.52	35.19	21.74
c10	50.52	48.54	59.45	47.62	48.85	90.91	95.05	95.83	79.52	80.00	83.84	85.78
c11	70.36	72.25	80.06	70.02	73.29	87.94	95.61	98.71	87.54	89.22	93.54	94.20
c12	43.09	39.19	54.22	41.98	33.23	85.07	87.76	88.77	68.76	72.79	70.46	76.54
c13	82.80	81.65	83.30	80.81	82.05	100.00	100.00	100.00	81.66	84.36	99.79	100.00
c14	92.84	92.56	93.84	92.36	92.28	92.49	71.27	98.42	93.62	94.81	98.56	98.56
c15	36.92	35.50	42.04	37.32	33.08	97.51	91.96	99.46	66.97	71.13	92.72	92.18
c16	93.10	92.98	92.32	93.00	91.87	88.96	59.69	83.87	64.46	73.20	68.31	68.88
AA	56.67	55.70	60.88	55.80	54.66	86.81	80.64	89.99	70.17	73.07	83.38	82.04
OA	58.83	57.60	64.56	58.29	56.86	87.81	86.23	87.82	80.20	80.96	87.69	88.02



- サンプル数の多いカテゴリでは一貫して優れた性能を示すが、サンプル数の少ないカテゴリでは性能が低下する



## 理由

- ColAEがスーパーピクセル間の多様体構造をモデル化するためにLLEを利用するため
  - LLEはK-最近傍の概念を採用しており、Kはデータの局所構造を捉るために、サンプル総数よりもはるかに小さい値に設定されることが多い
  - しかし、サンプルが数個しかないカテゴリは、限られた数のスーパーピクセル内に限定される傾向がある
  - その結果、多様体構造をモデル化するとき、LLEはこれらの小さなカテゴリを他のカテゴリと誤って関連付けるかもしれません、サンプル数の少ないカテゴリの分類精度が低くなる

サンプル数

c7 : 28

c9 : 20

c16 : 93

## Salinas データセット

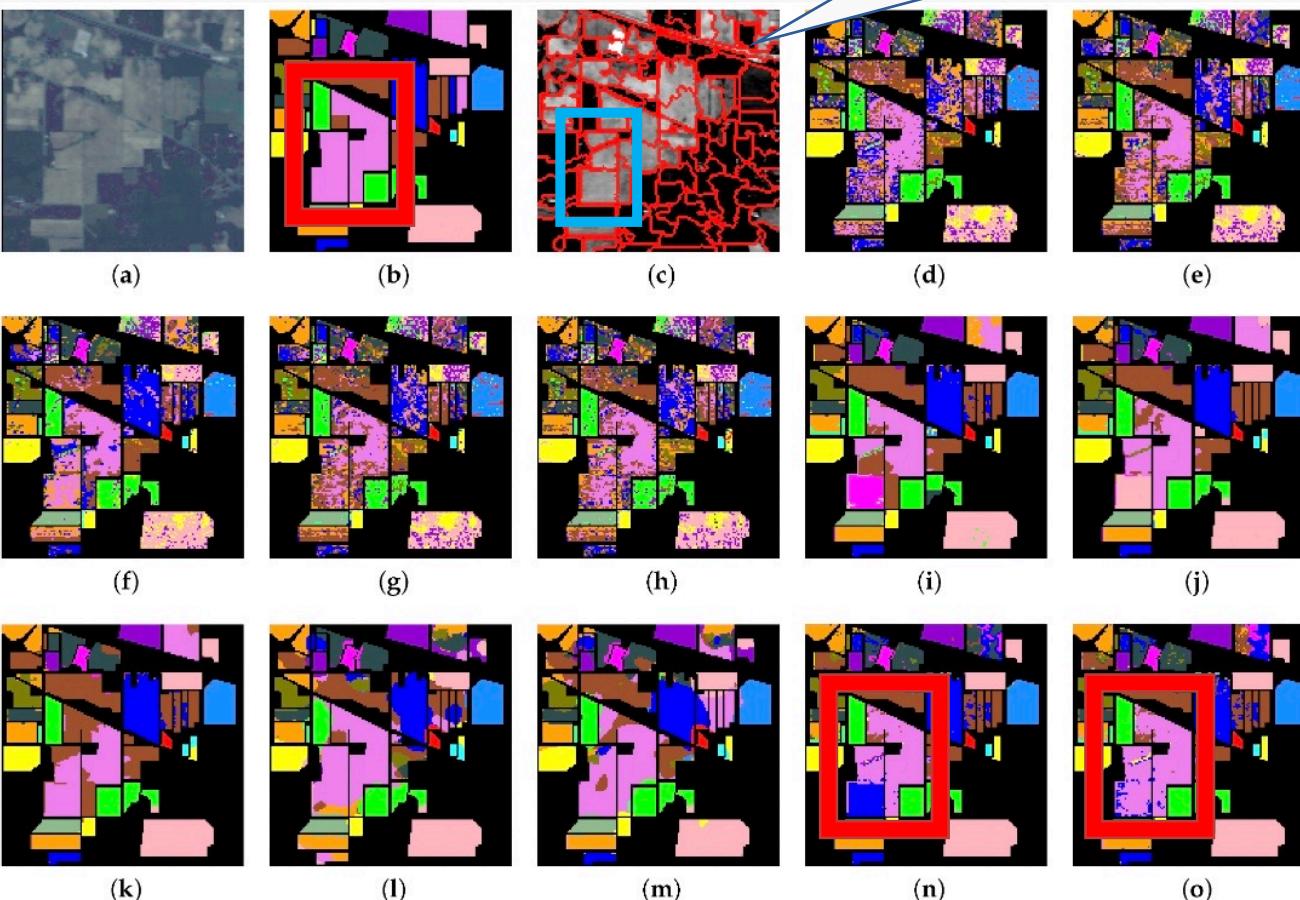
												Raw	PCA	LPP	AE	Super PCA	Super LPP	Super KPCA	Contrast Net	CAE	SuperAE	ColAE							
												c1	97.70	97.70	99.38	98.74	99.97	100.00	100.00	97.07	98.84	100.00	100.00						
												c2	98.46	98.43	98.37	99.07	99.85	99.17	100.00	96.31	99.00	99.88	99.88						
												c3	91.23	91.16	89.20	91.73	98.52	98.23	96.05	95.95	96.08	99.99	99.79						
												c4	96.92	96.93	98.76	97.25	96.70	95.86	97.23	93.71	82.88	96.57	96.57						
University of Pavia データセット												c5	96.71	96.69	95.07	96.58	95.67	77.29	95.76	91.82	98.68	98.29	98.14						
Raw				PCA	LPP	AE	Super PCA	Super LPP	Super KPCA	Contrast Net	CAE	SuperAE	ColAE	c6	99.78	99.78	99.72	99.95	99.18	100.00	99.82	99.68	99.72	100.00	100.00				
													c7	98.41	98.35	98.66	99.03	99.70	99.68	99.83	94.04	99.39	99.76	99.80					
													c8	78.45	77.98	78.25	78.54	98.33	99.92	91.29	90.08	95.41	98.04	97.18					
													c9	98.89	98.84	99.24	99.23	98.05	98.04	90.32	98.61	99.67	99.13	99.12					
													c10	84.89	85.56	81.05	86.07	94.58	88.31	88.43	95.29	95.48	91.68	91.85					
													c11	78.10	77.99	75.48	80.91	88.41	62.57	89.76	77.67	89.15	98.79	98.68					
													c12	95.79	95.82	96.70	96.69	94.39	97.79	83.71	96.75	97.50	98.79	98.82					
													c13	94.76	94.65	98.99	96.43	98.21	99.55	96.10	93.98	98.56	98.63	98.12					
													c14	86.24	86.06	92.66	89.05	90.93	88.71	85.20	97.68	97.78	91.63	92.63					
													c15	68.46	69.54	69.06	66.18	98.57	90.82	99.87	84.75	87.41	90.34	92.32					
													c16	98.22	98.28	98.16	98.01	99.15	98.99	96.77	95.85	98.99	99.29	99.25					
AA				78.84	78.84	69.32	77.40	90.79	85.38	89.52	93.34	92.49	93.30	93.61	AA				91.44	91.48	91.80	92.09	96.89	93.43	94.38	93.70	95.91	97.55	97.63
OA				80.57	80.66	70.13	79.35	92.60	82.48	91.37	95.02	94.08	95.16	95.39	OA				88.14	88.16	88.39	88.16	97.06	94.62	94.25	92.84	95.52	97.06	97.20

# 実験結果 (8/) : 訓練結果 (分類図)

22

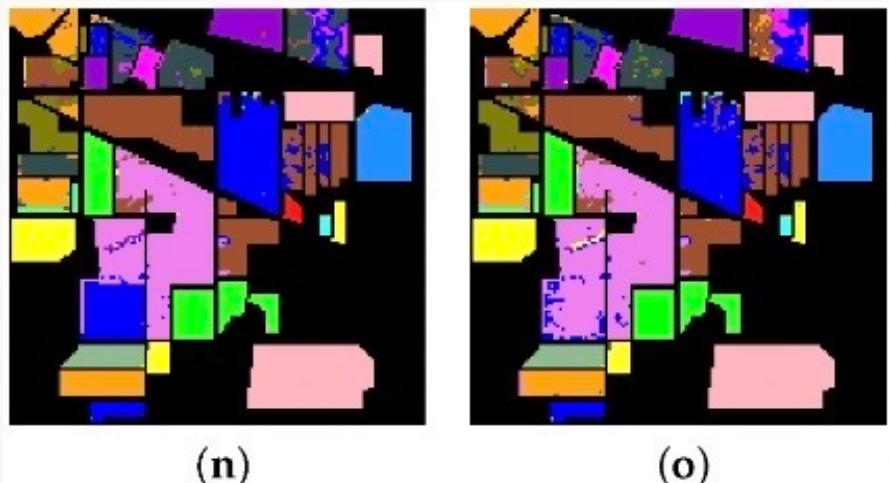
Figure 4. Classification maps produced by different algorithms for the Indian Pines data set. (a) False color map by band 29, 19, 9. (b) Ground truth map. The black area denotes the background pixels. (c) The segmentation with 100 superpixels. (d) Raw feature (OA = 57.72%). (e) PCA (OA = 57.20%). (f) LPP (OA = 69.04%). (g) KPCA (OA = 57.27%). (h) AE (OA = 56.71%). (i) SuperPCA (OA = 83.65%). (j) SuperLPP (OA = 83.34%). (k) SuperKPCA (OA = 85.22%). (l) ContrastNet (OA = 79.98%). (m) CAE (OA = 82.15%). (n) SuperAE (OA = 84.68%). (o) ColAE (OA = 87.24%).

異なるスーパーピクセル領域



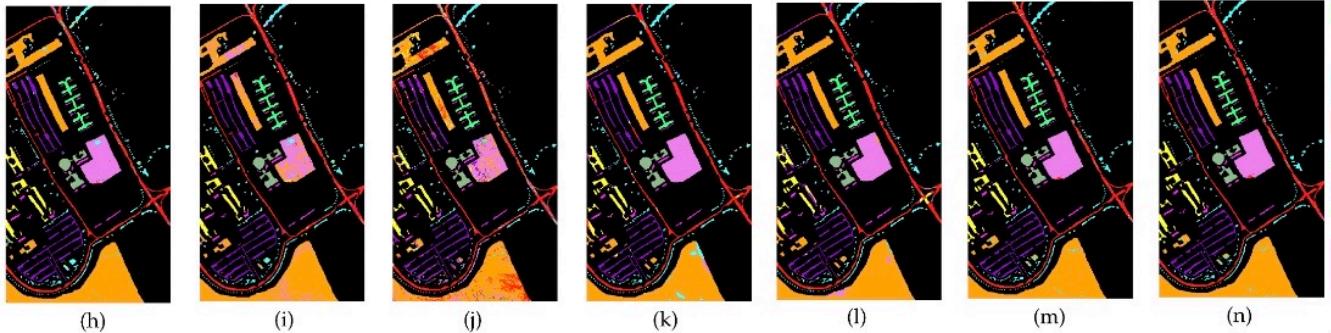
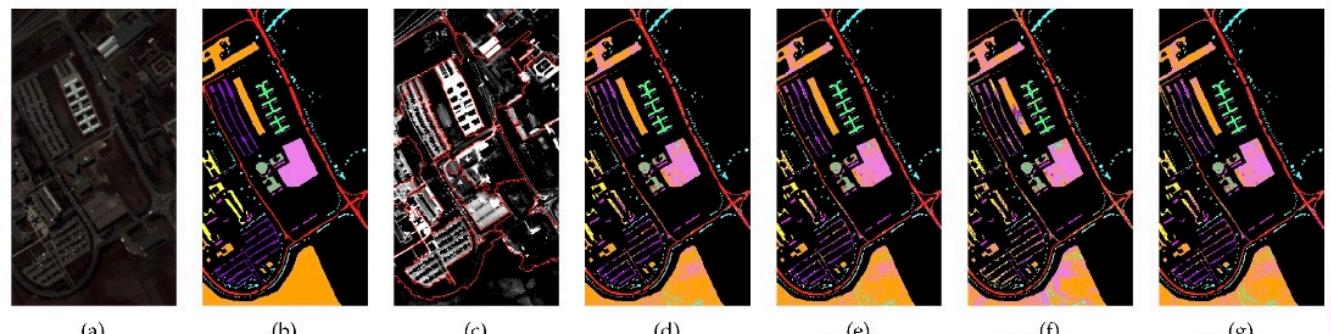
## ● Soybean-mintill (ピンクで表示)において

- (n) SuperAE
  - Soybean –nottill (青色で表示) と誤認識
- (o) ColAE
  - 大きな領域を正しく分類することができている



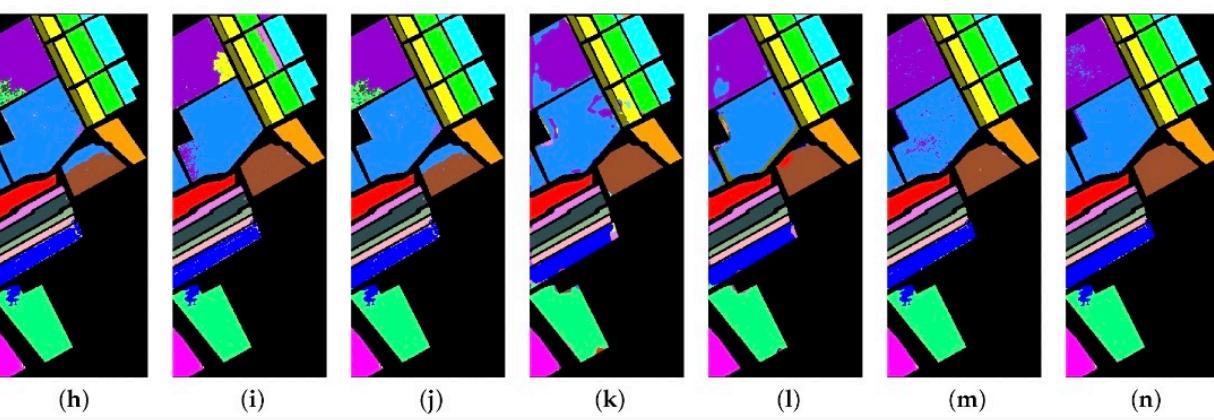
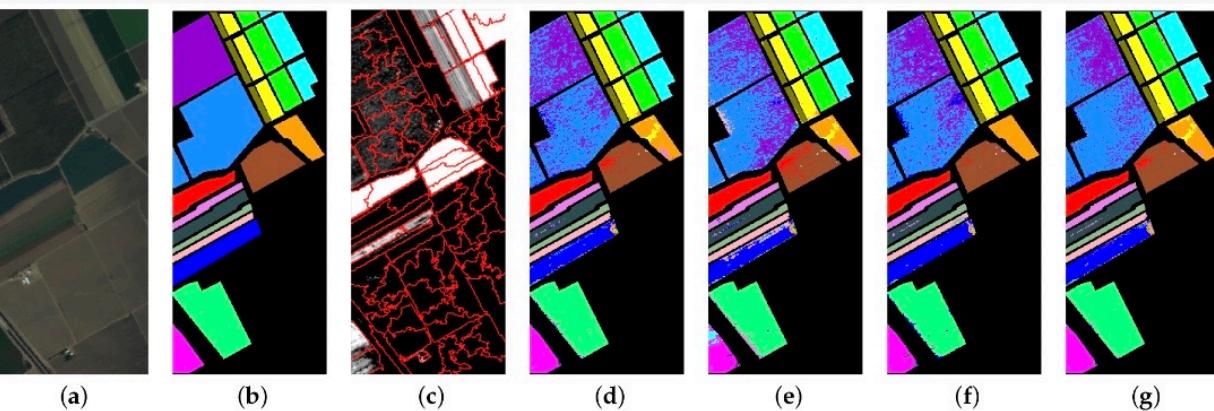
## University of Pavia データセット

**Figure 5.** Classification maps produced by different algorithms for the University of Pavia campus data set. (a) False color map by band 60, 30, 2. (b) Ground truth map. The black area denotes the background pixels. (c) The segmentation with 20 superpixels. (d) Raw feature (OA = 82.66%). (e) PCA (OA = 82.81%). (f) LPP (OA = 68.70%). (g) AE (OA = 81.81%). (h) SuperPCA (OA = 95.83%). (i) SuperLPP (OA = 87.70%). (j) SuperKPCA (OA = 94.22%). (k) ContrastNet (OA = 95.32%). (l) CAE (OA = 94.36%). (m) SuperAE (OA = 96.73%). (n) ColAE (OA = 96.78%).



## Salinas データセット

**Figure 6.** Classification maps produced by different algorithms for the Salinas data set. (a) False color map by band 50, 30, 20. (b) Ground truth map. The black area denotes the background pixels. (c) The segmentation with 100 superpixels. (d) Raw feature (OA = 87.30%). (e) PCA (OA = 86.74%). (f) LPP (OA = 87.86%). (g) AE (OA = 87.89%). (h) SuperPCA (OA = 94.25%). (i) SuperLPP (OA = 94.12%). (j) SuperKPCA (OA = 93.89%). (k) ContrastNet (OA = 93.38%). (l) CAE (OA = 95.27%). (m) SuperAE (OA = 97.43%). (n) ColAE (OA = 97.67%).



- **スーパーピクセルベース手法の優位性（○）**

- スペクトル-空間情報から特徴量を得るSuperAEとCoIAEは、スペクトル領域のみから特徴量を得るCAEとContrastNetと比較して、アーキテクチャがよりシンプルにもかかわらず上回っている

- **スーパーピクセルベース手法の柔軟性**

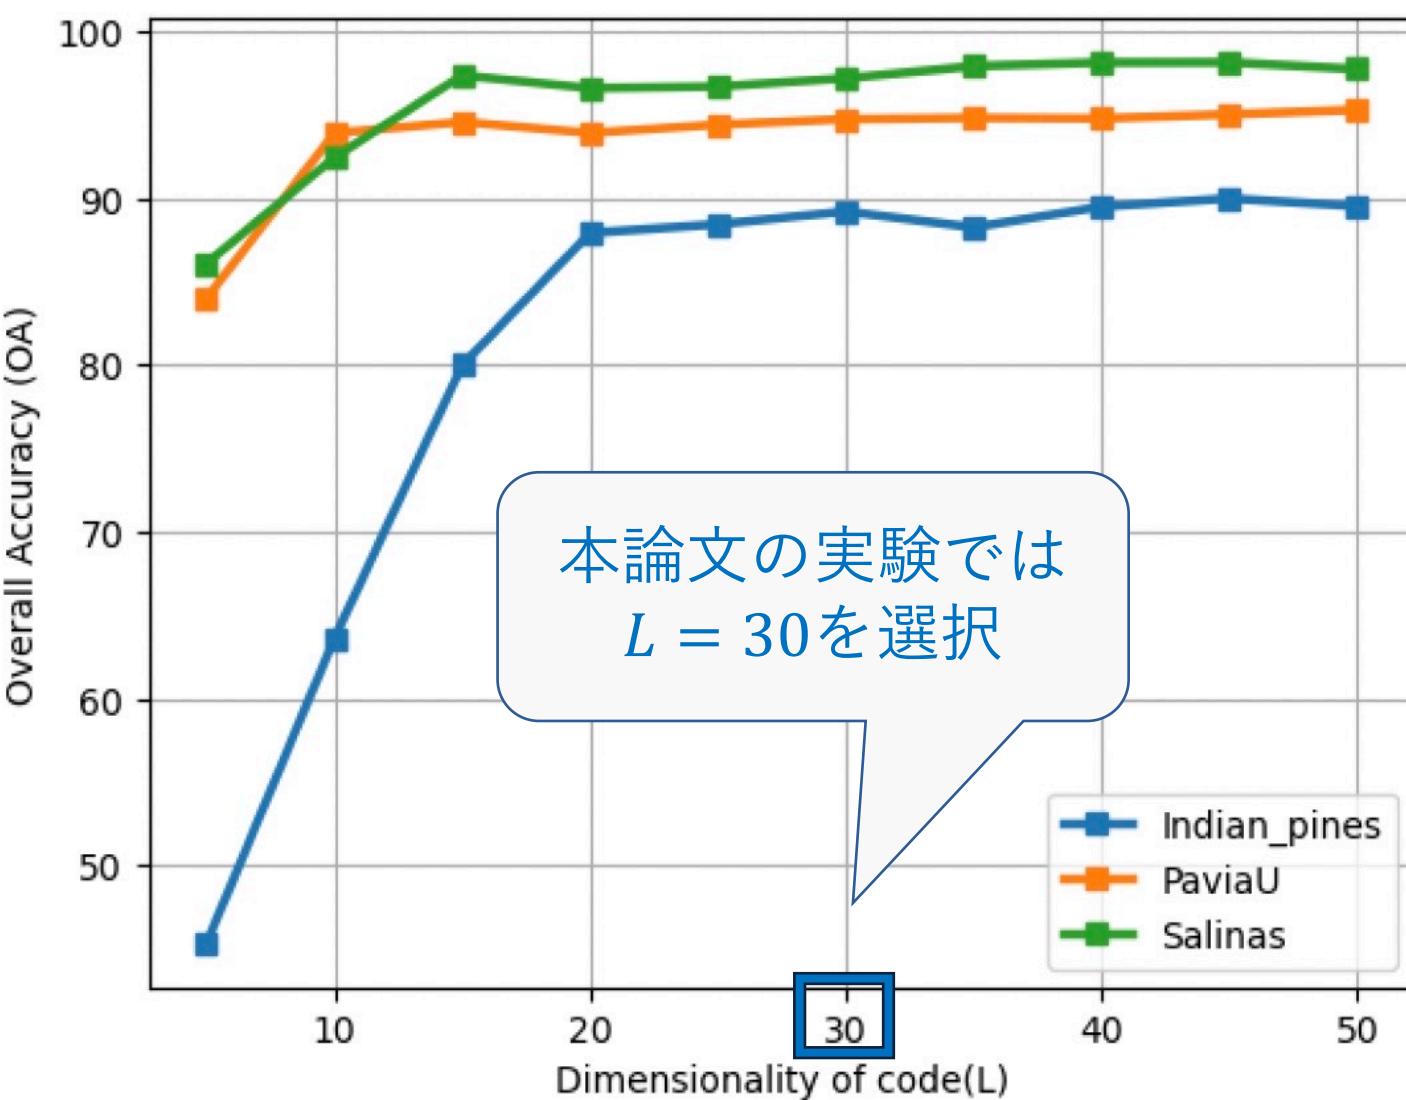
- SuperKPCAは従来のKPCAに比べてメモリ消費量が大幅に少ない

- SuperPCAはすべての結果において高い性能を示した
  - スーパーピクセル内の基本的なデータ構造が比較的単純であることを示す
  - わずか2つのレイヤーを持つAEの使用を正当化する
  - SuperAEとCoIAEの性能がSuperPCAより優れていることは、汎化性能の向上を示す
- SuperKPCAとSuperLPPの性能が一貫してSuperPCAを上回っていない
  - パラメータチューニングに採用されたグリッド探索戦略が、探索空間内に最適なパラメータを含める必要があるため
  - データ分布はスーパーピクセルごとに異なるため、SuperKPCAとSuperLPPのパラメータを正確にチューニングして最適な性能を達成することは困難である

- PCAは、Raw featureと同等の性能であることを示した
  - PCAで保持された主成分の割合は、Indian Pines: 99.25%, University of Pavia: 99.96%, Salinas: 99.99%である
  - PCAが貴重な情報を持たない成分を除去することができ、性能がほとんど低下しないことを示す
- LPPとKPCAは、PCAより高い性能を示した
  - HISに内在するデータ構造が複雑で、データの非線形構造を保持できるため
- AEは、Raw featureやPCAより若干低い性能を示した
  - 非線形関数が1つしかない2層Encoderの能力が限られているため（AE, SuperAE, ColAEのアーキテクチャは意図的に統一している）

- 最近傍の数  $K$ 
  - Indian Pines と Salinas  $K = 100$
  - University of Pavia  $K = 20$
- 固定比率  $R = 0.2$  ( $K = [J \times R]$ )
- 損失の正規化係数  $\eta = 0.75$
- SVMの  $T = 20$
  
- **Indian Pines**
  - $L = 45$  のとき、 89.89% と OA が最大
  - $L = 5$  のとき、 45.34% と OA が最小
  
- **University of Pavia**
  - $L = 45$  のとき、 95.30% と OA が最大
  - $L = 5$  のとき、 84.01% と OA が最小
  
- **Salinas**
  - $L = 45$  のとき、 98.14% と OA が最大
  - $L = 5$  のとき、 86.09% と OA が最小

**Figure 7.** The OAs vs. L in the Indian Pines, University of Pavia, Salinas data sets.



# 実験結果 (14/) : CoIAEのパラメータの分析

28

Indian PinesのOA: 85.39-89.37%

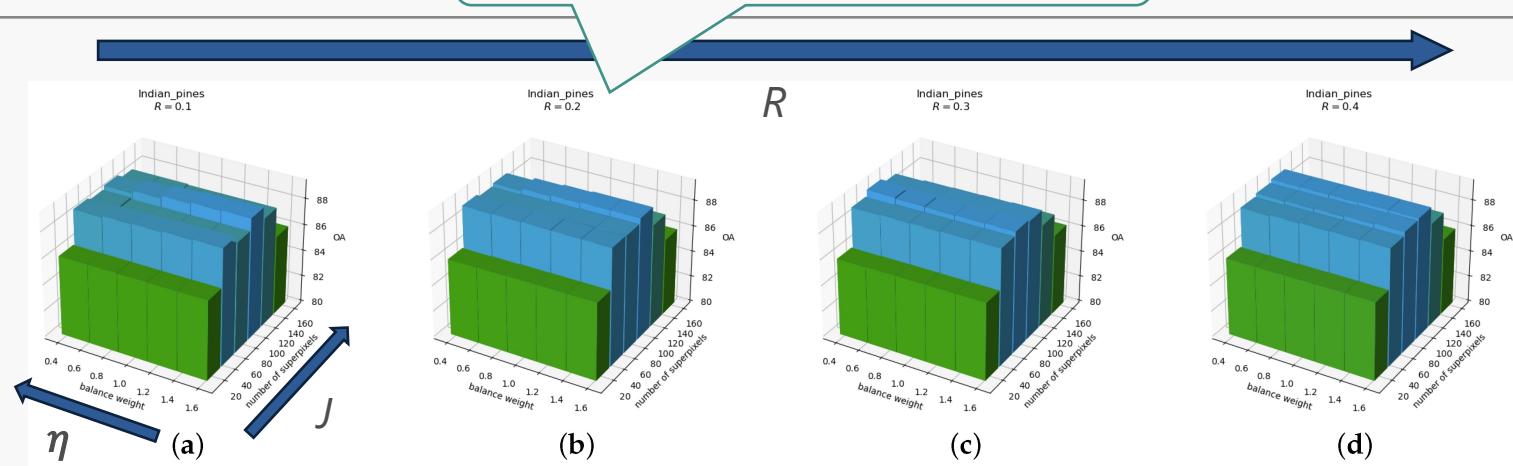
- 削減後の次元数  $L = 30$
- 損失の正規化係数  $\eta$  [0.5, 0.75, 1, 1.25]
- スーパーピクセルの数  $J$   
[20, 50, 70, 100, 120, 150]
- $J$  と  $K$  の比率  $R$  [0.1, 0.2, 0.3, 0.4]

## $J$ がCoIAEの性能に与える影響

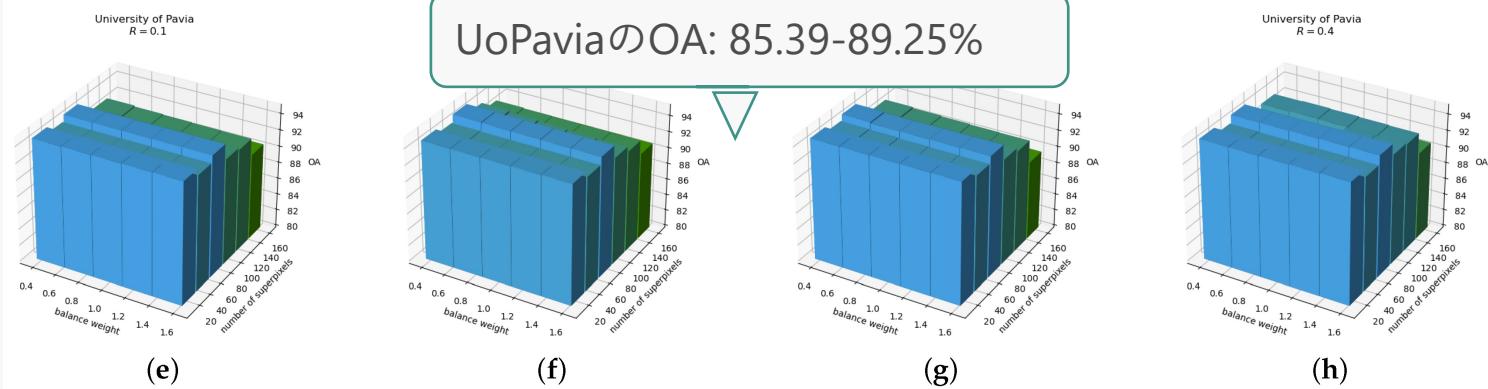
- $J$  が少なすぎると異なるクラスのサンプルがマージされてしまう可能性がある
- $J$  が多すぎるとスーパーピクセル内のサンプル数が少なくなる  
→ CoIAEフレームワークにおけるAEの学習能力が制限される

## $K$ と $\eta$ の変化はCoIAEの性能に影響しない

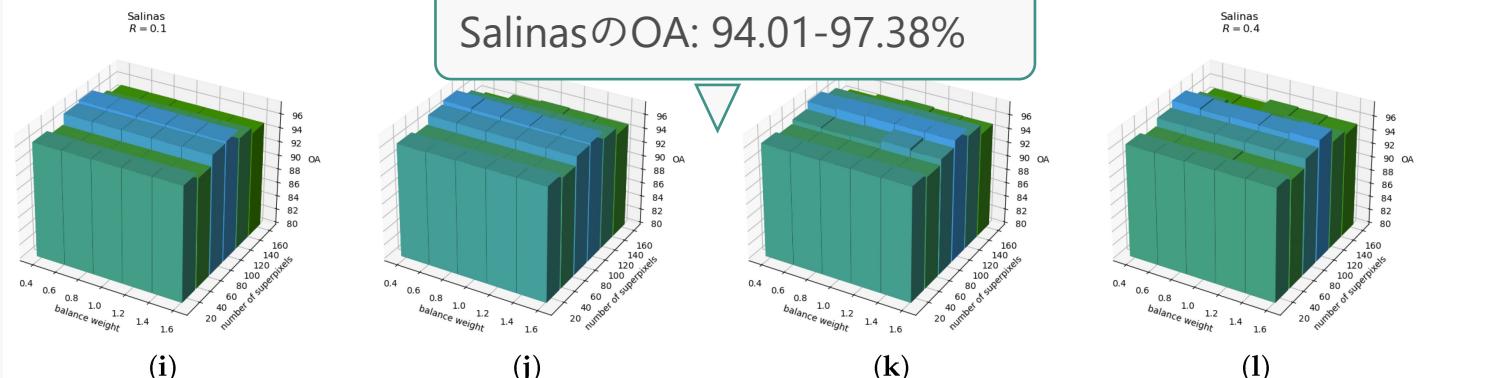
- 他のデータセットへの適応が可能である



UoPaviaのOA: 85.39-89.25%



SalinasのOA: 94.01-97.38%



## ● 訓練時間

- CPUを使用
- CAEとContrastNetの実装はGPUを使用  
(公平性のために表にはない)
- Indian Pines:  
 $145 \times 145 = 21,025$
- University:  
 $610 \times 340 = 207,400$
- Salinas:  
 $512 \times 217 = 111,104$

**Table 7.** Training time (in seconds) of nine DR methods on three HSI data sets.

	PCA	LPP	KPCA	AE	SuperPCA	SuperLPP	SuperKPCA	SuperAE	CoIAE
Indian Pines	0.09	85.12	628.87	53.23	1.03	90.64	524.66	58.34	58.45
University of Pavia	0.91	104.21	-	214.12	1.22	277.22	1245.12	158.58	160.10
Salinas	0.73	102.12	-	198.72	1.47	232.98	1862.23	132.43	134.22

## ● 結果の考察

- PCAはパラメータがないため計算時間が最も短い
- KPCAとSuperKPCAは、最も計算時間がかかる
  - パラメータ $\tau$ を調整する必要がありサイズ $N \times N$ の密カーネル行列を構築するため
  - パラメータチューニングのためのグリッド探索戦略はさらに計算量を増加される
- LPPとSuperLPPは計算量が大幅に軽減される
  - グリッド探索を用いるが、 $K \times K$ の疎行列を構築するだけであるため
- CoIAEは、SuperAEと同様の計算時間である
  - CoIAEには多様体グラフ行列を構築するステップが追加されるが、グラフ行列のサイズは $J$ と比較的小さい
- AEの計算時間はSuperAEやCoIAEと比べて長くなる
  - SuperAEとCoIAEは、スーパーピクセル内の全てのサンプルが任意に入力されるが、AEのバッチサイズは256に設定されているため

## ● 本論文概要

- 既存のスーパーピクセルベース次元削減手法がデータのクラス内部構造を乱す可能性があることを発見した
- この問題を解決するために、ColAEという教師なしスペクトル空間次元削減手法を提案

## ● ColAE

- まずHSIをスーパーピクセルに分割し、各スーパーピクセルからの平均ベクトル間の類似性をモデル化するためにLLEグラフを構築する
- 各スーパーピクセル内のサンプルにはAEが適用され、LLEグラフはコード空間内の表現の不一致を低減するために使用される
- 3つのHSIデータセットを用いた実験結果から、スーパーピクセルベースのDR手法の課題に対処する上で、提案するColAEが有効であることが検証できる

## ● 今後

- ColAEはマルチスケールスーパーピクセルバージョンに拡張可能であり、より高い分類精度が期待できる
- さらに、スーパーピクセル間の関係をモデル化するために、他の多様体学習ベースのグラフを利用することも、今後の研究の焦点となる